SERCOP — Servicio Nacional de Contratacion Publica
Coordinacion de Tecnologia de la Informacion

ANEXOS
Informe Tecnico IT-DIO-2026-206
SercoBot — Asistente Virtual de Contratacion Publica

Fecha: 16 de abril de 2026
Version: 1.0

Anexo	Titulo	Pagina
Anexo 1	Arquitectura tecnica detallada del sistema SercoBot	2
Anexo 2	Listado completo de documentos normativos indexados	4
Anexo 3	Informe de diagnostico de conectividad (13/04/2026)	5
Anexo 4	Ticket MANTIS — Habilitacion de infraestructura (15/04/2026)	7
Anexo 5	Resultados de pruebas funcionales — casos de uso validados	9

ANEXO 1 | Arquitectura tecnica detallada del sistema SercoBot

1.1 Diagrama de componentes

El sistema SercoBot esta compuesto por dos capas independientes que se integran a traves del modulo brain.py. La capa de mensajeria (WhatsApp) permanece estable y desacoplada de la capa de conocimiento normativo (RAG).

```
┌──────────────────────────────────────────────────────────────┐
│            CAPA DE MENSAJERIA (WhatsApp)                     │
│                                                              │
│  Meta Cloud API                                              │
│    └─> POST /webhook  [agent/main.py]                        │
│          ├─> parsear_webhook()  [providers/meta.py]          │
│          ├─> deduplicacion (_mensajes_procesados set)        │
│          ├─> [multimedia?] ──> _responder_multimedia()       │
│          └─> background: _procesar_mensaje()                 │
│                ├─> obtener_historial()  [memory.py]          │
│                ├─> generar_respuesta()  [brain.py]  ──┐      │
│                ├─> guardar_mensaje()    [memory.py]   │      │
│                └─> enviar_mensaje()     [meta.py]     │      │
│                                                       │      │
├───────────────────────────────────────────────────────┼──────┤
│            CAPA DE CONOCIMIENTO (RAG + Tools)         │      │
│                                                       ▼      │
│  brain.py::generar_respuesta()                               │
│    ├─> [shortcut?]  ──> respuesta fija (0ms, 0 tokens)       │
│    ├─> LLM 1ra llamada: ?tool_calls                          │
│    │     ├─> obtener_montos_pie()     [tools.py]             │
│    │     ├─> recomendar_tipo_contratacion() [tools.py]       │
│    │     ├─> obtener_plazos(tipo)     [tools.py]             │
│    │     ├─> info_rup()               [tools.py]             │
│    │     └─> obtener_fecha_hora_ecuador() [tools.py]         │
│    ├─> buscar_contexto(query)         [retriever.py]         │
│    │     ├─> expand_query (siglas SERCOP)                    │
│    │     ├─> embed (nomic-embed-text 768d via Ollama)        │
│    │     ├─> HNSW coseno pgvector (top-12 semantico)         │
│    │     ├─> GIN tsvector español (top-N lexico)             │
│    │     ├─> RRF fusion (top-12 unicos)                      │
│    │     └─> cross-encoder reranker (top-4 final)            │
│    └─> LLM 2da llamada: gemma4:e2b (Ollama)                  │
│          └─> respuesta con citacion de articulo              │
│                                                              │
├──────────────────────────────────────────────────────────────┤
│            INFRAESTRUCTURA                                   │
│                                                              │
│  PostgreSQL 16 + pgvector 0.8.2  (192.168.2.2:5432)          │
│    ├─ tabla: documentos (17 registros)                       │
│    ├─ tabla: chunks (3,059 registros + embeddings 768d)      │
│    └─ tabla: mensajes (historial de conversaciones)          │
│                                                              │
│  Ollama  (localhost:11434)                                   │
│    ├─ gemma4:e2b  — LLM principal (~5s/respuesta)            │
```

```
│     └─ nomic-embed-text — embeddings 768d                    │
│                                                               │
│  FastAPI + Uvicorn  (192.168.9.230:8000)                      │
│  Citrix reverse proxy  (192.168.100.131)                      │
│  NAT perimetral  (157.100.62.125:443)                         │
│  DNS: sercobot.sercop.gob.ec                                  │
└───────────────────────────────────────────────────────────────┘
```

1.2 Flujo de red — publicacion institucional

Capa	Componente	IP / Host	Puerto
DNS publico	sercobot.sercop.gob.ec	157.100.62.125	443 HTTPS
Firewall / NAT	Firewall perimetral SERCOP	157.100.62.125	443 → interno
DMZ red 100	IP interna asignada por TI	192.168.100.131	443
Citrix reverse proxy	Publicacion institucional	192.168.100.131	443 → 8000
Servidor aplicacion	FastAPI SercoBot	192.168.9.230	8000
Base de datos RAG	PostgreSQL 16 + pgvector	192.168.2.2	5432
Motor IA	Ollama (gemma4:e2b + nomic-embed)	localhost	11434

1.3 Stack tecnologico

Componente	Tecnologia	Version	Rol
Servidor API	FastAPI + Uvicorn	0.104+ / 0.24+	Webhook WhatsApp y endpoints admin
LLM produccion	gemma4:e2b via Ollama	Gemma 4 / v0.20+	Generacion de respuestas en lenguaje natural
Embeddings	nomic-embed-text via Ollama	768 dimensiones	Vectorizacion de chunks y queries
Vector DB	PostgreSQL 16 + pgvector	16 / 0.8.2	Busqueda hibrida semantica + lexica
Reranker	cross-encoder mmarco-mMiniLMv2	L12-H384-v1	Re-ordenamiento de chunks por relevancia
Mensajeria	Meta Cloud API	v21.0	Recepcion y envio de mensajes WhatsApp
BD conversaciones	PostgreSQL 16 (asyncpg)	16	Historial de conversaciones por usuario
Sistema operativo	RHEL 9.3	9.3	Servidor de produccion
Lenguaje	Python	3.11	Backend completo

ANEXO 2 | Listado completo de documentos normativos indexados

La base de conocimiento de SercoBot contiene 3,059 chunks distribuidos en 17 documentos. El 91.5% de los chunks incluye metadata de articulo para citacion legal precisa.

#	Documento	Tipo	Chunks	% con articulo
1	Reglamento General LOSNCP — octubre 2025	reglamento	1,132	100%
2	Normativa Secundaria de Contratacion Publica 2025	reglamento	1,125	100%
3	LOSNCP — RO 140 07-X-2025	ley	113	100%
4	Modelo de Pliego SICAE	resolucion	141	97%
5	Metodologia de Control Final Sumillada	resolucion	137	97%
6	Codigo de Etica institucional	resolucion	89	97%
7	Manual SOCE — Subasta Inversa Electronica	manual_soce	108	1%
8	RE-SERCOP-2026-0001 (Metodologia de Control)	resolucion	60	97%
9	RE-SERCOP-2026-0002 (Comite Interinstitucional)	resolucion	42	97%
10	Norma Interna SICAE (farmacos y bienes estrategicos)	resolucion	33	97%
11	Instructivo Extorsion	resolucion	29	97%
12	Resolucion Regimen de Transicion — nov. 2025	resolucion	14	97%
13	Manual SOCE — Fase Contractual Bienes y Servicios	manual_soce	19	1%
14	RE-SERCOP-2024-0144	resolucion	5	97%
15	RE-SERCOP-2025-0152	resolucion	5	97%
16	Fe de Errata RE-SERCOP-2024-0142	resolucion	1	97%
17	Glosario de Terminos SERCOP	manual	6	0%
	TOTAL	17 documentos	3,059	91.5%

Nota: Los manuales SOCE (manual_soce) tienen 1% de metadata de articulo porque son documentos procedimentales, no normativos. Es el comportamiento esperado.

Documentos pendientes de indexar

Documento	Tipo	Prioridad	Por que importa
Manual SOCE — Menor Cuantia bienes/servicios	manual_soce	Alta	Proceso mas comun en contratacion publica
Manual SOCE — Menor Cuantia obras	manual_soce	Alta	Segundo proceso mas frecuente
Manual SOCE — Registro de Proveedores	manual_soce	Alta	Alta demanda de ciudadanos nuevos
Manual SOCE — Contrataciones de Emergencia	manual_soce	Media	Preguntas frecuentes en situaciones urgentes
Manual SOCE — Feria Inclusiva	manual_soce	Media	Audiencia EPS y MIPYMES
COA (Codigo Organico Administrativo)	ley	Media	Capitulos de recursos e impugnaciones formales
Resolucion montos PIE 2026	resolucion	Alta	Fuente citable oficial para umbrales USD 2026

ANEXO 3 | Informe de diagnostico de conectividad (13/04/2026)

Script ejecutado: scripts/detectar_firewall.py | Equipo: JRUI-L9790-UIO | Fecha: 2026-04-13 09:46

Servicios locales

Servicio	Host:Puerto	Estado	Observacion
Ollama (LLM + embeddings)	localhost:11434	BLOQUEADO	Servicio no activo en ese momento — ahora en produccion
PostgreSQL (base RAG)	localhost:5432	BLOQUEADO	Servicio no activo en ese momento — ahora en VM pg-db (192.168.2.2)
FastAPI (servidor del bot)	localhost:8000	BLOQUEADO	Servicio no activo en ese momento — ahora corriendo en 192.168.9.230:8000

Meta WhatsApp API

Servicio	Host:Puerto	Estado	Observacion
graph.facebook.com HTTPS	graph.facebook.com:443	PARCIAL / CRITICO	SSL rechazado por Citrix DPI — pendiente bypass Franklin Arias
graph.facebook.com DNS	graph.facebook.com:443	ABIERTO	Resolucion DNS correcta (28ms)

Portal SERCOP y acceso a internet

Servicio	Host:Puerto	Estado	Latencia
compraspublicas.gob.ec	portal.compraspublicas.gob.ec:443	ABIERTO	27ms — HTTP 200
sercop.gob.ec	www.sercop.gob.ec:443	ABIERTO	16ms — HTTP 200
PyPI (dependencias Python)	pypi.org:443	ABIERTO	41ms — HTTP 200
Docker Hub	registry-1.docker.io:443	ABIERTO	110ms
Ollama Download (modelos LLM)	registry.ollama.ai:443	ABIERTO	22ms
DNS publico Google	8.8.8.8:53	BLOQUEADO	DROP silencioso
HuggingFace (reranker)	huggingface.co:443	PARCIAL	SSL rechazado — bypass habilitado 15/04

Resumen y acciones resultantes

Metrica	Valor
Total pruebas realizadas	12
Conexiones abiertas	6 (50%)
Conexiones bloqueadas	4 (33%)
Conexiones parciales	2 (17%)
Criticos sin resolver al 13/04	4 servicios (Ollama local, PostgreSQL local, Meta HTTPS, DNS externo)
Estado al 15/04/2026	Resuelto: Ollama + PostgreSQL en produccion. Pendiente: graph.facebook.com SSL bypass

Accion pendiente critica: solicitar a Franklin Arias (Administrador de Firewall) agregar graph.facebook.com a la lista de bypass de inspeccion SSL del firewall perimetral. Sin esta habilitacion el bot genera respuestas pero no puede entregarlas al usuario via Meta API.

ANEXO 4 | Ticket MANTIS — Habilitacion de infraestructura (15/04/2026)

Sistema: MANTIS 14860/11289 — SERCOP

Datos del ticket

Campo	Valor
Numero de ticket	Pendiente asignacion MANTIS
Titulo	Habilitacion de infraestructura para SercoBot — Asistente Virtual SERCOP
Proyecto	TIC — Infraestructura y Operaciones
Categoria	Solicitud de servicio
Prioridad	Alta
Estado final	Resuelto (parcialmente — ver pendientes)
Fecha apertura	2026-04-13
Fecha resolucion	2026-04-15
Solicitante	Mauricio Ruiz — Analista de Desarrollo TIC
Asignado a	Rolando Coello (DNS) / Franklin Arias (Firewall) / Hugo Yepez (Autorizacion)

Hilo de atencion — cronologia

Fecha / Hora	Responsable	Accion realizada	Estado
2026-04-13 09:46	Mauricio Ruiz	Ejecucion script diagnostico_firewall.py — identificacion de bloqueos criticos	Completado
2026-04-13 10:00	Mauricio Ruiz	Envio de solicitud formal al equipo TIC con reporte de firewall adjunto	Completado
2026-04-14	Equipo TIC	Revision de solicitud — aprobacion por Hugo Yepez	Completado
2026-04-15 17:34	Hugo Yepez	Autorizacion formal del proyecto SercoBot para publicacion institucional	Completado
2026-04-15 19:48	Franklin Arias	Habilitacion reglas NAT perimetral: puertos 443 y 80 desde 157.100.62.125 hacia 192.168.100.131	Completado
2026-04-15 20:16	Rolando Coello	Configuracion DNS interno: sercobot.sercop.gob.ec -> 192.168.100.131	Completado
2026-04-15 20:30	Mauricio Ruiz	Verificacion publica: curl https://sercobot.sercop.gob.ec/ -> HTTP 200	Completado
Pendiente	Franklin Arias	Agregar graph.facebook.com a bypass de inspeccion SSL (Citrix DPI)	Pendiente
Pendiente	Franklin Arias	Agregar github.com a bypass SSL para habilitar git pull en servidor	Pendiente

Reglas de firewall habilitadas el 15/04/2026 (Franklin Arias)

#	Servicio	Host destino	Puerto	Uso
1	Groq API	api.groq.com	443	LLM en la nube (respaldo)
2	Meta WhatsApp	graph.facebook.com	443	Envio y recepcion de mensajes WhatsApp Business
3	Cloudflare Tunnel	*.cloudflare.com	443	Tunel alternativo de publicacion
4	GitHub	github.com	443	Control de versiones del codigo
5	GitHub objetos	objects.githubusercontent.com	443	Descarga de releases y assets de GitHub
6	PyPI	pypi.org	443	Instalacion de dependencias Python
7	PyPI archivos	files.pythonhosted.org	443	Descarga de paquetes Python
8	Ollama	ollama.com / registry.ollama.ai	443	Descarga de modelos LLM
9	HuggingFace	huggingface.co	443	Descarga del modelo reranker cross-encoder
10	HuggingFace CDN	cdn-lfs.huggingface.co	443	CDN de archivos de modelos HuggingFace

Infraestructura provisionada

Componente	Detalle	Responsable	Fecha
Dominio publico	sercobot.sercop.gob.ec	Rolando Coello	2026-04-15
IP publica	157.100.62.125 — NAT perimetral puertos 443 y 80	Franklin Arias	2026-04-15
IP interna DMZ (red 100)	192.168.100.131 / mask 255.255.255.0 / GW .35	Rolando Coello	2026-04-15
Servidor aplicacion	192.168.9.230 — puerto 8000 (FastAPI)	Mauricio Ruiz	2026-04-15
Publicacion	Citrix reverse proxy HTTP->HTTPS	Franklin Arias	2026-04-15
Base de datos RAG	PostgreSQL 16 + pgvector 0.8.2 (192.168.2.2)	Mauricio Ruiz	2026-04-14
Autorizacion institucional	Hugo Yepez — 2026-04-15 17:34	Hugo Yepez	2026-04-15

ANEXO 5 | Resultados de pruebas funcionales — casos de uso validados

Las pruebas funcionales se realizaron el 15 y 16 de abril de 2026 sobre el entorno de produccion (sercobot.sercop.gob.ec). Se validaron los 9 escenarios criticos definidos en el documento de prueba de escritorio PED-DIO-2026-206.

5.1 Tabla de resultados por caso de uso

N.	Caso de uso	Entrada de prueba	Resultado esperado	Resultado obtenido	Estado
CU-01	Saludo puro -> menu bienvenida	"hola"	Menu de bienvenida con 5 categorias. Sin llamada al LLM.	Recibido menu completo en < 500ms. Sin consumo de tokens.	PASA
CU-02	Pregunta normativa -> RAG + articulo	"causales de suspension del RUP"	Respuesta con causales y citacion Art. 16-18 LOSNCP.	Respuesta correcta con citacion Art. 16 LOSNCP. RAG devolvio 4 chunks relevantes.	PASA
CU-03	Monto infima cuantia -> tool	"cuanto es el monto de infima cuantia"	Monto exacto 2025 ($7,263) via tool obtener_montos_pie.	Monto correcto $7,263. Tool invocada. RAG no consultado.	PASA
CU-04	Monto menor cuantia -> tool	"hasta cuanto es menor cuantia de bienes"	Monto $72,630 con base legal Art. 51 LOSNCP.	Monto correcto $72,630. Art. 51 citado.	PASA
CU-05	Plazo de impugnacion -> tool	"cuantos dias tengo para impugnar"	3 dias habiles desde notificacion. Art. 102 LOSNCP.	Plazo correcto 3 dias habiles. Art. 102 LOSNCP citado.	PASA
CU-06	Plazo firma de contrato -> tool	"en cuantos dias se firma el contrato"	15 dias habiles desde adjudicacion. Art. 69 LOSNCP.	Plazo correcto 15 dias. Art. 69 citado.	PASA
CU-07	Comparacion de procesos -> tools paralelas	"diferencia entre cotizacion y menor cuantia"	Tabla comparativa con montos de ambos procesos en USD.	Comparacion correcta: $72,630 vs $72,630-$544,725. 3 tools invocadas.	PASA
CU-08	Que proceso usar -> recomendar_tipo_contratacion	"que proceso uso para comprar computadoras por $50,000"	Recomendacion: Menor Cuantia bienes/servicios.	Proceso correcto identificado. Monto y normativa correctos.	PASA
CU-09	Como ser proveedor -> info_rup + RAG	"quiero vender al estado, por donde empiezo"	Pasos del RUP como primer paso obligatorio. Art. 16-18 LOSNCP.	info_rup() invocada primero. Pasos correctos. Costo $0 citado.	PASA
CU-10	Fecha actual -> tool fecha	"que dia es hoy"	Fecha y hora actual en Ecuador (UTC-5).	Fecha correcta. Tool obtener_fecha_hora_ecuador invocada.	PASA
CU-11	Mensaje multimedia (audio)	Nota de voz de WhatsApp	Respuesta orientativa sin invocar LLM. < 1s.	Mensaje 'Solo puedo responder texto' enviado en < 800ms.	PASA
CU-12	Mensaje duplicado (reintento Meta)	Mismo mensaje_id enviado 2 veces	Solo una respuesta entregada al usuario.	Segunda solicitud ignorada. Log: 'Mensaje duplicado ignorado'.	PASA
CU-13	Pregunta fuera de scope	"cual es la capital de Francia"	Redireccionar al scope de contratacion	Bot indica que solo atiende temas de contratacion publica.	PASA

			publica.		
CU-14	Sigla SIE reconocida	"que es la SIE"	Respuesta sobre Subasta Inversa Electronica. Art. 47 LOSNCP.	Sigla expandida correctamente. Art. 47 LOSNCP citado.	PASA
CU-15	Envio de respuesta via Meta API	Cualquier mensaje procesado correctamente	Respuesta entregada al usuario por WhatsApp.	PENDIENTE — graph.facebook.com bloqueado por Citrix DPI. Bot genera respuesta pero no puede enviarla.	PENDIENTE

5.2 Resumen de resultados

Metrica	Valor
Total casos evaluados	15
Casos PASA	14 (93.3%)
Casos PENDIENTE	1 (6.7%) — entrega final por Citrix DPI
Casos FALLA	0
Tiempo promedio de respuesta	~6 segundos (RAG + gemma4:e2b) / < 500ms (shortcuts)
Precision de citacion legal	100% de casos con RAG activo
Alucinacion de articulos	0 casos detectados
Herramientas (tools) invocadas	5 de 5 tools validadas

5.3 Pendiente critico

CU-15 — Entrega de respuesta via Meta API: el sistema genera y procesa la respuesta correctamente pero la entrega final al usuario de WhatsApp falla porque el firewall perimetral aplica inspeccion SSL (Citrix DPI) sobre el dominio graph.facebook.com, restableciendo la conexion TCP al momento del handshake TLS.

Accion requerida: Franklin Arias debe agregar graph.facebook.com a la lista de dominios excluidos de inspeccion SSL en el firewall Citrix. Una vez aplicado este cambio, el CU-15 quedara resuelto y el sistema estara 100% operativo.