Informe Técnico y Solicitud de Infraestructura

Sistema SARA — Asistente Virtual de Contratación Pública

Para: Ing. Paúl Vásquez Méndez **Cargo:** Director de Infraestructura y Operaciones **Unidad:** Coordinación de Tecnología de la Información y Comunicaciones — SERCOP **Fecha:** Abril 2026 **Asunto:** Estado del sistema SARA y requerimientos de infraestructura para puesta en producción

---

1. Resumen Ejecutivo

El sistema **SARA** (Sistema de Asesoría y Respuesta Automatizada) ha sido desarrollado e instalado exitosamente en el servidor de producción del SERCOP. SARA es un asistente virtual de WhatsApp que responde preguntas ciudadanas sobre normativa de contratación pública, citando artículos de la LOSNCP, el Reglamento General y resoluciones vigentes.

Las pruebas técnicas han sido completadas con resultados satisfactorios: tiempos de respuesta de **1 a 2 segundos** y respuestas precisas con citación normativa. El sistema está listo para conectarse a WhatsApp Business y entrar en operación, pendiente únicamente de la habilitación de infraestructura de red descrita en este documento.

---

2. Estado Actual del Sistema

2.1 Componentes instalados y funcionando

Componente	Estado	Ubicación
Servidor de la aplicación (FastAPI)	✅ Operativo	`app-bdd-chatbot` puerto 8000
Motor de IA local (Ollama + qwen2.5:3b)	✅ Operativo	`app-bdd-chatbot` puerto 11434
Base de datos de conversaciones (PostgreSQL)	✅ Operativo	`app-bdd-chatbot` puerto 5432
Base de conocimiento normativa (RAG)	✅ Operativo	PostgreSQL local — 3,059 fragmentos
Modelo de embeddings (nomic-embed-text)	✅ Operativo	Ollama local
API de IA externa (Groq — Llama 4 Scout 17B)	✅ Configurado	api.groq.com
Túnel Cloudflare (cloudflared)	✅ Instalado	`app-bdd-chatbot`
Conexión a WhatsApp Business (Meta API)	⏳ Pendiente configuración webhook	Requiere URL pública estable

2.2 Base de Conocimiento Normativa

El sistema tiene indexados **3,059 fragmentos** de 17 documentos oficiales:

Documento	Tipo
Reglamento General LOSNCP — octubre 2025	Reglamento
Normativa Secundaria de Contratación Pública 2025	Reglamento
LOSNCP — Registro Oficial 140, 07-X-2025	Ley
Manual SOCE — Subasta Inversa Electrónica	Manual
RE-SERCOP-2026-0001, 0002 y otras resoluciones	Resoluciones
Modelo de Pliego SICAE, Código de Ética, Instructivos	Varios

2.3 Capacidades del Asistente

Capacidad	Descripción
Consultas normativas	Responde con citación de artículo (LOSNCP, RGLOSNCP, Resoluciones)
Montos de contratación	Umbrales exactos 2025/2026 por tipo de proceso (ínfima cuantía, menor cuantía, licitación, etc.)
Plazos	Días hábiles por proceso, impugnación, contratos y garantías
Registro de Proveedores	Requisitos, costos y proceso del RUP
Tipo de proceso	Orientación sobre qué modalidad usar según monto y objeto
Fecha y hora Ecuador	Información en tiempo real

2.4 Rendimiento Comprobado

Métrica	Resultado
Tiempo de respuesta promedio	**1.1 — 1.9 segundos**
Tiempo de respuesta máximo	< 3 segundos
Usuarios simultáneos soportados (plan gratuito)	Hasta 30 por minuto
Conversaciones diarias (plan gratuito)	~200 por día
Disponibilidad del servidor local	24/7 (proceso del sistema operativo)

---

3. Arquitectura de la Solución

```
CIUDADANO / PROVEEDOR DEL ESTADO
        │ WhatsApp
```

```
            ▼
    ┌──────────────────┐
    │  Meta WhatsApp   │  ← Canal de comunicación
    │  Business API    │
    └──────────────────┘
            │
            │ HTTPS (webhook)
            ▼
    ┌──────────────────┐
    │  Cloudflare CDN  │  ← Termina el TLS / HTTPS
    │  sara.sercop.gob.ec│    Certificado automático
    └──────────────────┘
            │
            │ Túnel cifrado (saliente desde servidor)
            ▼
    ┌──────────────────────────────────────┐
    │     SERVIDOR app-bdd-chatbot — SERCOP  │
    │                                      │
    │  SARA (FastAPI)      → procesa consulta │
    │  Base normativa RAG  → busca normativa  │
    │  Ollama (IA local)   → embeddings       │
    │  PostgreSQL          → historial        │
    └──────────────────────────────────────┘
                  │
                  │ HTTPS saliente
                  ▼
    ┌──────────────────┐
    │   Groq API       │  ← Genera la respuesta
    │ (Llama 4 Scout)  │    en lenguaje natural
    └──────────────────┘
```

Principio de seguridad: El servidor no recibe conexiones externas directas. Todo el tráfico entrante pasa por Cloudflare Tunnel, que el servidor establece como conexión saliente. No se requiere abrir puertos de entrada en el firewall.

---

4. Requerimientos de Infraestructura para Producción

4.1 Solicitud al Equipo de DNS

Crear el siguiente registro en el servidor DNS institucional del SERCOP:

Campo	Valor
Tipo de registro	CNAME
Nombre	`sara`
Dominio resultante	`sara.sercop.gob.ec`
Destino (apunta a)	`<ID_TUNEL>.cfargotunnel.com` *(TIC entrega el ID)*
TTL	300 segundos

> El ID del túnel será proporcionado por la Coordinación TIC una vez confirmada esta solicitud. El proceso toma menos de 5 minutos una vez que TIC ejecuta el comando de creación del túnel.

Certificado HTTPS: Cloudflare emite y renueva automáticamente el certificado SSL/TLS para `sara.sercop.gob.ec`. El equipo de redes no requiere gestionar ningún certificado.

4.2 Solicitud al Equipo de Firewall / Citrix

REGLAS OBLIGATORIAS — Sin estas el sistema no opera

#	Destino	Puerto	Protocolo	Para qué sirve
1	`api.groq.com`	443	HTTPS	Motor de IA — genera las respuestas
2	`graph.facebook.com`	443	HTTPS	Envío de respuestas a WhatsApp
3	`*.cloudflare.com`	443	HTTPS	Túnel — recepción de mensajes WhatsApp
4	`*.cfargotunnel.com`	443	HTTPS	URL del túnel en producción
5	`cloudflareaccess.com`	443	HTTPS	Autenticación del túnel
6	`region1.v2.argotunnel.com`	7844	TCP+UDP	Canal de datos del túnel (rendimiento)
7	`region2.v2.argotunnel.com`	7844	TCP+UDP	Canal de datos del túnel (redundancia)

REGLAS DE MANTENIMIENTO — Para actualizaciones del sistema

#	Destino	Puerto	Protocolo	Para qué sirve
8	`github.com`	443	HTTPS	Actualizaciones del código fuente
9	`objects.githubusercontent.com`	443	HTTPS	Archivos de GitHub
10	`pypi.org`	443	HTTPS	Dependencias Python
11	`files.pythonhosted.org`	443	HTTPS	Paquetes Python

REGLAS DE MODELOS IA — Solo instalación inicial (pueden ser temporales)

#	Destino	Puerto	Protocolo	Para qué sirve
12	`ollama.com`	443	HTTPS	Descarga de modelos de IA locales
13	`registry.ollama.ai`	443	HTTPS	Repositorio de modelos Ollama
14	`huggingface.co`	443	HTTPS	Modelo de búsqueda semántica
15	`cdn-lfs.huggingface.co`	443	HTTPS	Archivos de modelos IA

> Una vez instalados los modelos de IA (#12-15), estas reglas pueden eliminarse.

---

5. Consideraciones de Privacidad y Seguridad

Aspecto	Detalle
Datos que permanecen en SERCOP	Base de datos normativa (3,059 fragmentos), historial de conversaciones, modelos de IA locales, código fuente
Datos que salen al exterior	Texto de las consultas ciudadanas y fragmentos normativos relevantes viajan a Groq (EE.UU.) para generar la respuesta. Se recomienda revisión del área legal bajo la normativa de protección de datos del Ecuador.
Cifrado	Todo el tráfico usa TLS 1.3 (HTTPS). El túnel Cloudflare agrega una capa adicional de cifrado.
Puertos de entrada	Ninguno. El servidor no acepta conexiones externas directas.
Alternativa 100% local	Si la restricción de datos impide el uso de Groq, el sistema puede operar con el modelo de IA local (Ollama) a un costo de ~50 segundos de respuesta en lugar de 1-2 segundos, sin requerir ninguna conexión externa para la generación de respuestas.

---

6. Costos Proyectados

Concepto	Costo	Frecuencia
Groq API — plan gratuito (hasta ~200 conv/día)	**$0**	Mensual
Groq API — plan de pago (si supera el gratuito)	**$3 — $56**	Mensual según uso
Cloudflare Tunnel	**$0**	Gratuito
Dominio `sara.sercop.gob.ec`	**$0**	Usa dominio institucional existente
Infraestructura del servidor	Ya existente	—

Costo operativo estimado para el primer año: $0 — $56/mes según volumen de uso, con infraestructura de servidor ya amortizada.

---

7. Pasos para Puesta en Producción

Una vez aprobada y ejecutada la habilitación de infraestructura:

Paso	Responsable	Acción
1	**Equipo Firewall**	Aplicar reglas de firewall (sección 4.2)
2	**Coordinación TIC**	Crear túnel: `cloudflared tunnel create sara` y entregar ID al equipo DNS
3	**Equipo DNS**	Crear registro CNAME `sara.sercop.gob.ec` con el ID entregado

Paso	Responsable	Acción
4	**Coordinación TIC**	Verificar HTTPS: `curl https://sara.sercop.gob.ec/`
5	**Coordinación TIC**	Registrar webhook en Meta: `https://sara.sercop.gob.ec/webhook`
6	**Coordinación TIC**	Activar SARA como servicio del sistema (systemd)
7	**Coordinación TIC**	Prueba funcional con número WhatsApp Business

Tiempo estimado de implementación: 1 día hábil una vez habilitada la infraestructura.

---

8. Verificación Técnica

Para confirmar que las reglas de firewall están correctamente aplicadas, ejecutar el script de diagnóstico incluido en el sistema:

```
cd /home/jonathan.ruiz/sara-sercop
python scripts/detectar_firewall.py --salida reporte_verificacion.txt
```

Genera un reporte con estado ✅/❌ por cada endpoint requerido.

Documento generado por la Coordinación de TIC — SERCOP Ecuador Sistema SARA v2.0 — Abril 2026